BTS Services Informatiques aux Organisations (SIO)
Option Solutions Logicielles et Applications Métiers (SLAM)

Rapport de stage BTS SIO option SLAM

Effectué du 5 janvier au 20 février 2026

Tuteur de l’entreprise : Jean-Marc MOREAU

Tuteur pédagogique : Christèle FERREIRA

Entreprise d'accueil : EXAEGIS (37)

Établissement : Lycée Paul-Louis Courier

Remerciements

Avant de débuter ce rapport de mon second stage, je tiens à remercier sincèrement l'entreprise **Exaegis** pour m'avoir accueilli au sein de son équipe avec convivialité et bienveillance. L'ambiance à la fois dynamique et détendue qui y règne m'a permis de m'intégrer rapidement et de travailler dans des conditions agréables.
Je souhaite également adresser mes remerciements à l'ensemble de l'équipe IT, composée de Jean 1, Jean 2,Ludovic, Alexandre ainsi que Jean-Marc, mon tuteur de stage. Grâce à son expérience, sa disponibilité et sa gentillesse, j'ai pu acquérir de nombreuses compétences tout au long de ces sept semaines, dans un cadre particulièrement formateur.

Sommaire

Remerciements....2
Introduction....4
Présentation de l'entreprise et du service....4
I - Activité et mission....4
II - Localisation....5
III - Organigramme hiérarchique et fonctionnelle....7
Présentation de l'environnement matériel et logiciel....7
I - Environnement matériel....7
II - Environnement logiciel....8
Présentation du contexte de la situation professionnelle....9
Récapitulatif des semaines....9
Semaine 1 :....9
Semaine 2 :....10
Semaine 3 :....11
Semaine 4 :....12
Semaine 5 :....13
Semaine 6 :....13
Étapes de résolution des tickets....15
Prise en charge du ticket....15
Test du script....16

Introduction

Ce stage de deuxième année est une étape obligatoire dans l'obtention du BTS Services Informatiques aux Organisations (SIO). Ce second stage dure 7 semaines et a pour objectif de valider et mettre en œuvre un certain nombre de compétences acquises au cours de ces deux dernières années. De plus il permet de se confronter au monde professionnel et de gagner en expérience.

Mon stage s'est déroulé au sein de l'entreprise **Exaegis**. L'entreprise conseille les professionnels dans toutes les décisions qui concernent le numérique. La partie qui suit présente justement l'entreprise et le service dans lequel j'ai été accueilli. Je vous présenterai ensuite l'environnement informatique de l'entreprise, puis la situation professionnelle qui a entouré mon stage et enfin un récapitulatif de ce que j'ai pu effectuer dans le cadre de ma mission.

Présentation de l'entreprise et du service

Exaegis est une SAS française spécialisée dans le conseil stratégique, l'analyse de données et l'évaluation de risques liés au numérique.

Exaegis est une **société par actions simplifiée (SAS)** française fondée en 2011, dont le siège social est situé **à Tours**. Elle compte **25 de salariés** et intervient principalement dans le **conseil pour les affaires et la gestion**.

I - Activité et mission

Exaegis aide les décideurs du secteur **numérique, des services tech et du financement** à **prendre des décisions stratégiques en toute confiance** en s'appuyant sur des **données fiables, des outils d'analyse et des audits**. Ses prestations couvrent notamment :

- **Analyse de marchés et études Sectorielles** ;
- **Audit technologique et évaluation de solutions** ;
- **Conseil stratégique, M&A et accompagnement financier** ;
- **Services de notation, de garantie opérationnelle et de confiance** pour sécuriser les collaborations.

En résumé, **Exaegis** est une **PME de conseil et d'analyse stratégique** tournée vers l'écosystème numérique, combinant expertise, données et outils pour **sécuriser et optimiser les décisions d'affaires**.

II - Localisation

Siège social d'**Exaegis** :

📍 **4 Rue Albert Dennery, 37000 Tours, FRANCE**

📍 **53 bis impasse des Louviers, 78100 Saint Germain en Laye, FRANCE**

📍**47 calle Juan Alvarez de Mendizabal, 28 008 Madrid, ESPAGNE**

📍**Viale Milanofiori, strada 3, 20 057 Assago, ITALIE**

📞 **02 46 99 17 31**

🌐 **http://www.exaegis.com/**

III - Organigramme hiérarchique et fonctionnelle

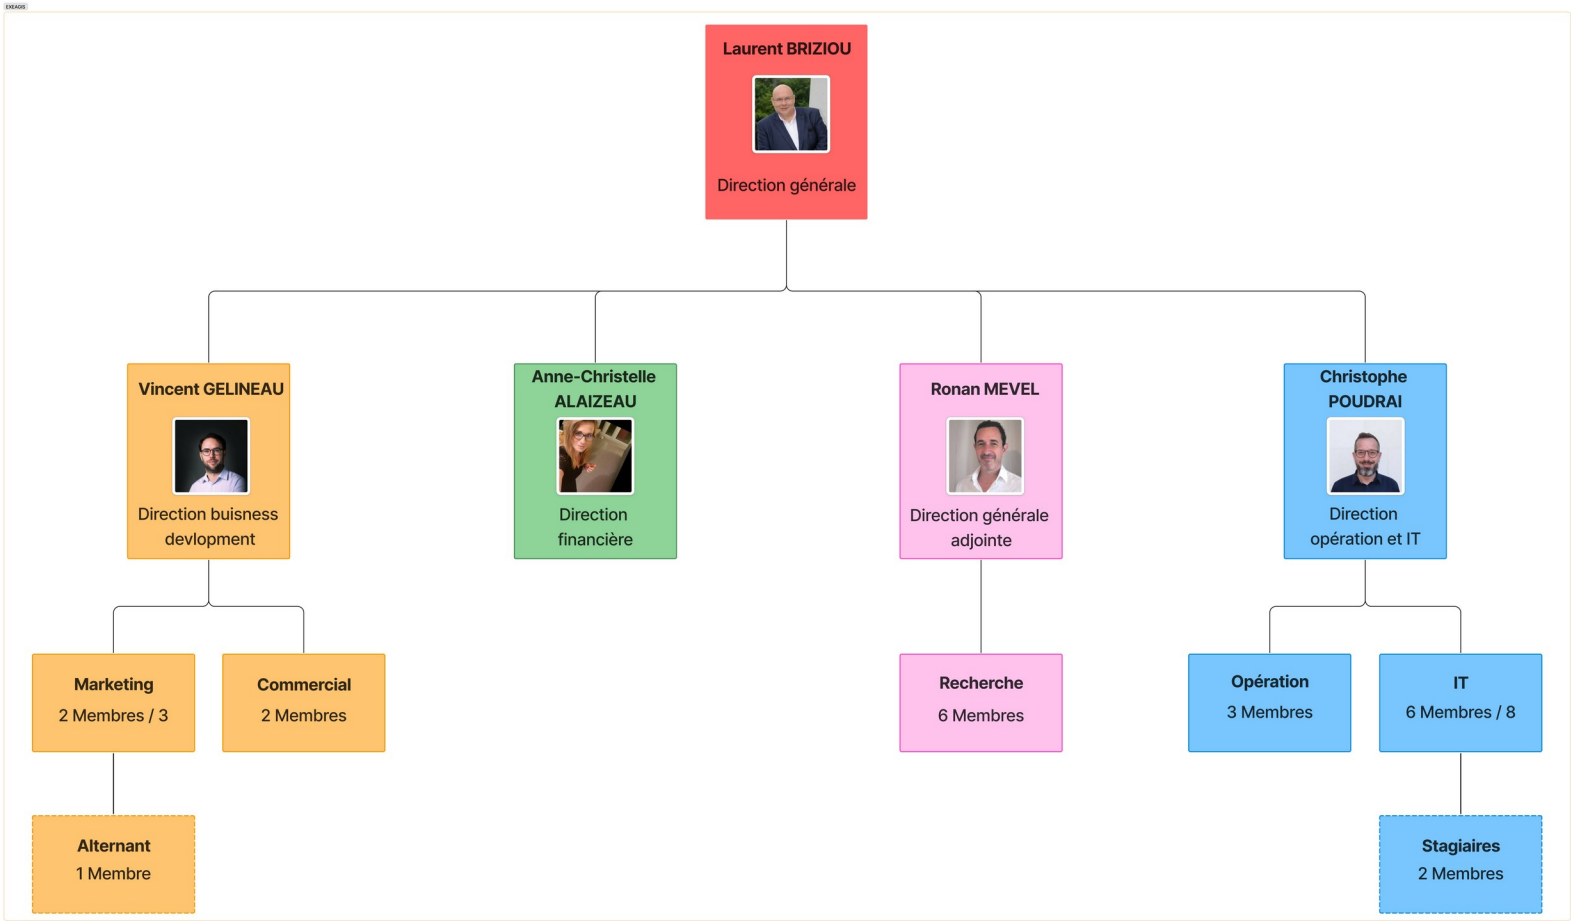

Présentation de l'environnement matériel et logiciel

I - Environnement matériel

Les employés d'**Exaegis** utilisent à la fois des **postes fixes et des ordinateurs portables**, ce qui permet une grande flexibilité dans l'organisation du travail. L'ensemble des postes fonctionne sous **Linux ou Windows**, un choix cohérent avec l'activité de conseil informatique, offrant stabilité, sécurité et souplesse d'administration.

L'infrastructure réseau permet la communication entre les postes de travail, les serveurs internes et les services externes.

II - Environnement logiciel

Les postes de travail fonctionnent sous **Linux ou Windows**. Pour la bureautique et les services collaboratifs, **Exaegis** utilise **Microsoft 365 (Office.com)**, ce qui permet :

- la création et le partage de documents (SharePoint),
- la gestion des e-mails professionnels (Outlook),
- le travail collaboratif en temps réel (Teams).

L'entreprise utilise **Microsoft Teams** comme outil principal de communication interne.
Teams permet les échanges instantanés, les réunions à distance et le partage de fichiers, facilitant ainsi le travail collaboratif, notamment en **télétravail**.

De mon côté pour développer j'ai utilisé IntelliJ IDEA comme IDE. Le langage de programmation était Java avec le framework Spring-Boot et le gestionnaire de dépendance Maven. J'ai également utilisé les framework Jsoup et Sélénium suivant si les sites utilisaient javaScript ou non.

Présentation du contexte de la situation professionnelle

L'entreprise possède un service dont l'objectif est de récupérer des documents administratifs (délibérations, vote du budget, actes administratifs, ...) renseignés sur les sites des différentes collectivités françaises. Après analyse par une IA, les documents récupérés vont permettre aux entreprises abonnées au service d'anticiper la mise sur marché public de projets liés au secteur du numérique, leur offrant un avantage concurrentiel et un temps pour préparer au mieux leur réponse. Le projet sert aussi à d'autres collectes sur le web (offres d'emploi, annonces diverses, etc.).
Chaque semaine, les scripts sont lancés en production pour scraper les documents administratifs. S'il y a une erreur, un ticket Jira est créé. C'est ici que j'interviens, mon rôle est de garantir la maintenance du code. Mes actions peuvent varier énormément car l'erreur peut venir simplement d'un cookie pas récupéré à un site entier à re-scraper car la collectivité l'a changé.

Récapitulatif des semaines

Semaine 1 :

Cette première semaine de stage a été consacrée à la découverte de l'entreprise, des outils de travail et à la prise en main de ma mission principale. Après la mise en place des accès nécessaires (session utilisateur, Office, Jira, GitLab), mon tuteur m'a présenté les objectifs du stage, qui consistent à maintenir et corriger des scripts de scraping permettant de récupérer les délibérations de différentes collectivités territoriales.

J'ai ensuite commencé à étudier le fonctionnement des scripts existants et les principes du scraping, notamment à travers l'utilisation du framework Jsoup. L'analyse de premiers tickets m'a permis de mieux comprendre la structure des scripts et les difficultés liées à l'évolution des sites web, notamment lorsque les données sont fournies sous forme de JSON.

Cette semaine s'est conclue par la résolution de mon premier ticket, suite à l'identification et la correction d'un problème lié au paramètre *offset* limitant la récupération des délibérations. Cette première réussite m'a permis de consolider mes connaissances techniques et de mieux appréhender la suite du stage.

Fonctionnement du scraping

Le script "main" appel le script "EgovGeneric" qui lui-même à besoins du script spécifique à la collectivité (ici celle de la ville de Tours). S'en suit plusieurs échange entre les 2 scripts (cf : *schéma ci-dessus*) pour que finalement la méthode "scrapeAllDocs()" du scipt de la collectivité ajoute les informations des délibérations à la base de donnée et renvoie les erreurs si il y en a.

Il est important de préciser que ce fonctionnement ne convient pas à tout les scripts. Certains utilisent d'autres méthodes.

Semaine 2 :

Cette seconde semaine de stage, écourtée en raison d'un séminaire d'entreprise, a été consacrée à la poursuite de la prise en main des outils et des différentes technologies de scraping utilisées.

Sur les conseils de mon tuteur, j'ai recherché des scripts utilisant **Selenium** afin d'élargir mes compétences. L'exécution de certains scripts a cependant révélé des problèmes techniques, notamment liés à la configuration du proxy. En attendant d'approfondir ce point, je me suis orienté vers un script utilisant **WebDelib**, concernant le département du Tarn-et-Garonne. L'analyse de ce script a mis en évidence des difficultés liées aux performances du site cible, entraînant des erreurs de type *timeout*, malgré plusieurs tentatives d'adaptation du code.

Par la suite, mon tuteur m'a expliqué plus en détail la gestion du proxy dans les scripts Selenium, ce qui m'a permis de mieux comprendre l'origine des erreurs rencontrées précédemment. Toutefois, d'autres dysfonctionnements, notamment des liens de délibérations non fonctionnels, ont conduit à mettre ce script de côté. Cette semaine m'a ainsi permis d'identifier de nouvelles problématiques techniques et de mieux appréhender la diversité et la complexité des scripts de scraping utilisés au sein de l'entreprise.

Ticket Tarn-et-Garonne

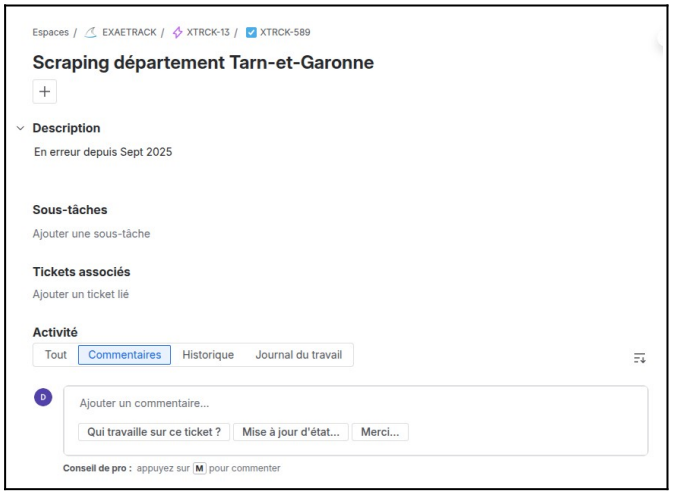

Aperçu du ticket Jira "Tarn-et-Garonne". Ceux qui rapporte le tickets et ceux qui tente de le résoudre, peuvent ajouter des commentaire pour décrire le problème

Erreur du script Tarn-et-Garonne

```
Fatal (lecture du DOM): Read timed out
On a déjà 0 documents pour TARN-ET-GARONNE entre 16/0
Aucun docuements ramenés depuis 6 mois, abandon
XXXXX close_scraping : ko  nb : 0
Scraping en échec; KO pour TARN-ET-GARONNE
 docs ramenés : 0
scraping ko : erreur de récupération des cookies
```

L'erreur "Read timed out" indique que la page ne charge pas.

Semaine 3 :

Cette troisième semaine de stage a été principalement consacrée à la maintenance et à la correction de nombreux scripts de scraping, en particulier ceux utilisant l'outil **WebDelib**. J'ai identifié un problème récurrent lié à la configuration du proxy : la majorité des sites **WebDelib** n'acceptaient plus le proxy Tor utilisé par défaut. J'ai donc testé individuellement une vingtaine de scripts afin de vérifier leur compatibilité. Seuls trois fonctionnaient encore avec Tor, ce qui m'a conduit à ajouter les autres scripts à la liste du proxy Squid. Ce travail de vérification, de correction et de gestion des branches a nécessité environ une journée.

Par ailleurs, j'ai résolu un dysfonctionnement sur le site de la ville de Colmar, où aucun document n'était récupéré malgré l'absence d'erreur apparente. Cette anomalie était due au passage de la collectivité vers **WebDelib+**, tout en conservant l'ancien site en ligne. La correction a consisté à modifier l'URL de connexion afin de cibler le nouveau site.

Enfin, j'ai corrigé deux autres problèmes distincts : l'un lié à l'utilisation d'un proxy par défaut non accepté, qui a dû être remplacé, et l'autre concernant le site de la ville d'Orléans. Dans ce dernier cas, le nom de la classe avait changé. L'inspecteur web ne trouvait donc pas l'élément recherché (*cf : recherche erroné*). J'ai donc fais correspondre le nom de classe du script avec celui de la page (*cf : recherche fonctionnelle*). Ces corrections ont permis de rétablir le bon fonctionnement du scraping.

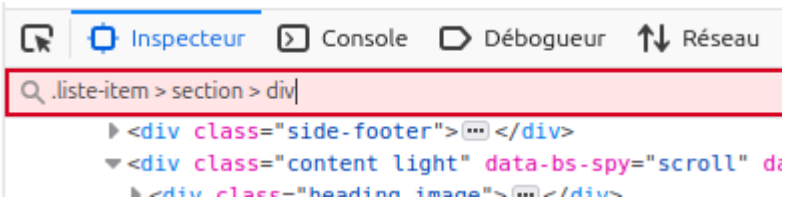

Recherche erroné

Recherche fonctionnelle

Semaine 4 :

Cette quatrième semaine de stage a été consacrée à la résolution de tickets de plus en plus complexe, notamment liés aux spécificités techniques des collectivités territoriales. J'ai notamment travaillé sur des scripts exploitant des données OpenData via des API, en particulier pour la métropole de Rennes. Ce ticket présentait un problème liées à l'absence de certains liens de téléchargement des délibérations, entraînant des erreurs lors de l'exécution des scripts. J'ai donc exploré plusieurs pistes de correction sans aboutir à une solution réellement satisfaisante, J'ai donc mis ce ticket de côté pour y revenir plus tard à tête reposé et si c'est le cas avec plus de connaissance et d'expérience.

Par ailleurs, cette semaine m'a permis de consolider ma compréhension de l'architecture globale du projet et du fonctionnement des scripts de scraping. Les tickets traités, bien que moins nombreux, ont abordé des problématiques variées telles que des changements de structure de pages web, des refus de proxy ou encore des erreurs lors de la récupération de données complémentaires comme les budgets. La résolution de plusieurs de ces tickets en fin de semaine a contribué à renforcer mes compétences techniques et mon autonomie dans la maintenance des scripts.

JSON de l'API OpenData de la métropole de Rennes


```
total_count:                2940
results:
  0:
    coll_nom:               "RENNES METROPOLE"
    coll_siret:             "24350013900189"
    delib_id:               "B22_351"
    delib_date:             "2022-09-15"
    delib_matiere_code:     7.3
    delib_matiere_nom:      "Finances locales/Emprunts"
    delib_objet:            "B22_351Habitat  Saint-Erblon  Les Basses Noë
    budget_annee:           null
    budget_nom:             null
    pref_id:                null
    pref_date:              null
    vote_effectif:          null
    vote_reel:              null
    vote_pour:              null
    vote_contre:            null
    vote_abstention:        null
    delib_url:              null
  1:
    coll_nom:               "RENNES METROPOLE"
    coll_siret:             "24350013900189"
    delib_id:               "C22_222"
    delib_date:             "2022-12-15"
    delib_matiere_code:     7.1
    delib_matiere_nom:      "Finances locales/Divers"
    delib_objet:            "C22_222Finances – Expérimentation Compte Fin
    budget_annee:           null
    budget_nom:             null
    pref_id:                null
    pref_date:              null
```


- "total_count" correspond au nombre total de délibérations pour la requête (ici toutes les délibérations)

- "delib_id" est la référence que l'on utilisera

- "delib_date" est la date de publication de la délibération

- "delib_objet" est le titre de la délibération

- "delib_url" est le lien vers le pdf de la délibération

Ainsi, sans le "delib_url" on ne peut pas accéder au contenu de la délibération.

Semaine 5 :

Mercredi, j'ai repris le traitement d'un ticket concernant la métropole de Rennes. Une API exploitable a été identifiée, celle-ci fournissant désormais des URL vers les délibérations au format PDF. J'ai pu finaliser et clôturer ce ticket en suivant les étapes de résolution prévues.

Par la suite, nous avons répondu aux questions relatives à l'entreprise en vue de la réalisation de la note de synthèse.

Enfin, Jean-Marc m'a signalé une erreur dans le script des Vosges que j'avais précédemment corrigé : les fichiers sont bien enregistrés, mais au format .zip. Une modification de la méthode sera donc nécessaire la semaine prochaine afin d'ajouter un argument approprié, ce qui pourra entraîner une adaptation des scripts utilisant cette méthode.

Semaine 6 :

Durant cette sixième semaine de stage, j'ai travaillé sur l'évolution et la correction de scripts liés à l'API Maelis. Je devais notamment ajouter un paramètre permettant de renseigner si le document était zippé ou non. L'ajout d'un paramètre par défaut n'étant pas possible en Java, deux solutions étaient envisageables pour modifier une méthode existante : soit modifier directement le constructeur et adapter l'ensemble des scripts concernés, soit surcharger la méthode en ajoutant un paramètre optionnel. Étant donné que seulement sept scripts utilisaient cette méthode, nous avons choisi la première solution, bien que plus longue à mettre en place.

La modification technique a été rapide, mais une grande partie du temps a été consacrée à l'analyse d'un problème lors du téléchargement de fichiers PDF. Avec Jean-Marc, nous avons constaté que les PDF retournés étaient vides et que le serveur renvoyait une erreur 429 (« Too Many Requests »). Après débogages, nous avons compris que le site redirigeait vers une page de vérification par captcha lors du téléchargement. Le script tentait alors de télécharger cette page HTML en tant que PDF, ce qui provoquait l'échec du téléchargement et l'enchaînement rapide des requêtes, entraînant l'erreur 429.

Par la suite, j'ai travaillé sur le script du département du Cantal. Celui-ci était relativement simple, mais j'ai constaté que toutes les délibérations étaient regroupées dans un seul fichier PDF. Cette organisation ne permet pas de traiter et stocker chaque délibération individuellement dans la base de données, contrairement au fonctionnement habituel.

Enfin, j'ai repris le script du département de la Creuse, qui a dû être presque entièrement réécrit en raison d'un changement du site. Deux problèmes majeurs ont été identifiés : d'une part, les annexes ne sont pas clairement distinguées des délibérations, ce qui empêche de les relier de manière fiable ; d'autre part, certaines dates

n’étaient pas reconnues par le script, ce qui bloquait la récupération des délibérations correspondantes. Après discussion avec Jean-Marc, nous avons estimé que le problème des annexes n’était pas bloquant. Par contre, le problème des dates a été résolu en modifiant le regex utilisée pour les extraire, ce qui a permis de récupérer l’ensemble des délibérations.

Regex de la fonction dateIntoString

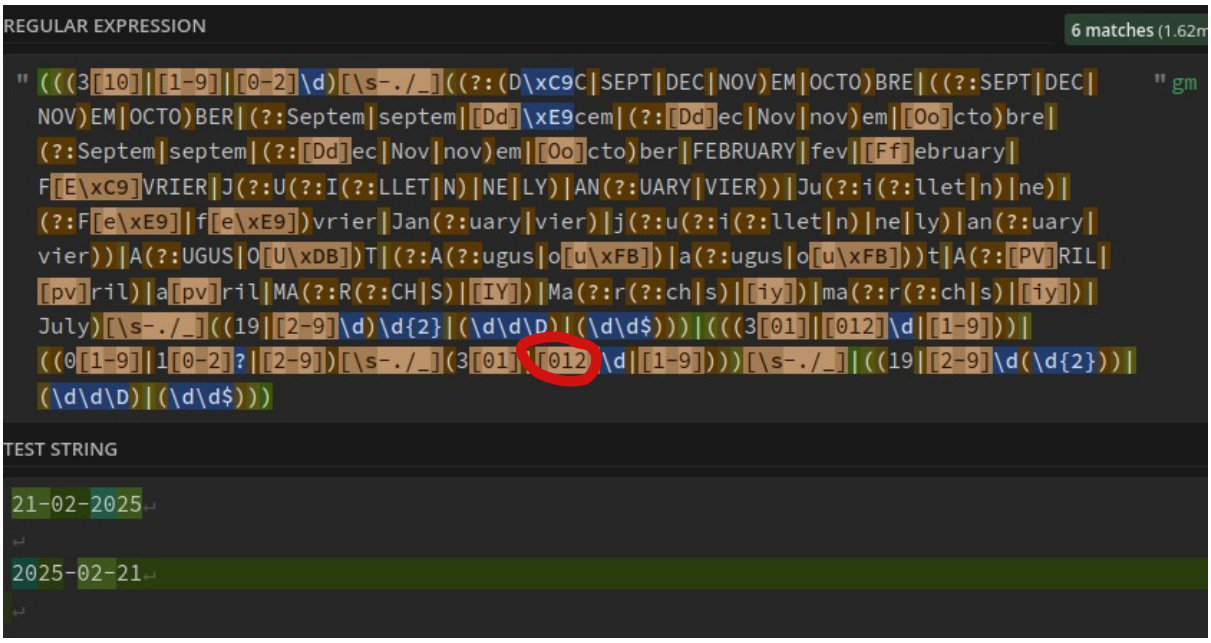

Rajout d’un 0 (entouré en rouge) pour sélectionner les 9 premiers mois de l’année.

Étapes de résolution des tickets

Prise en charge du ticket

Pour commencer il faut trouver un ticket et se l'attribuer.

Alors on commence par rechercher le ticket que l'on souhaite résoudre (ici, celui de la métropole de Rennes)

XTRCK-552	Scraping métropole Montpellier	Medium	Non assignée	À FAIRE
XTRCK-553	Scraping métropole Nantes	Medium	delalande	EN COURS
XTRCK-554	Scraping métropole Nice	Medium	Non assignée	À FAIRE
XTRCK-556	Scraping métropole Rennes	Medium	Non assignée	À FAIRE
XTRCK-557	Scraping métropole Toulon	Medium	Non assignée	À FAIRE
XTRCK-559	Scraping département Ain	Medium	Non assignée	À FAIRE

Puis on s'attribue le ticket, on le passe en "EN COURS" et on clique sur "Créer une branche"

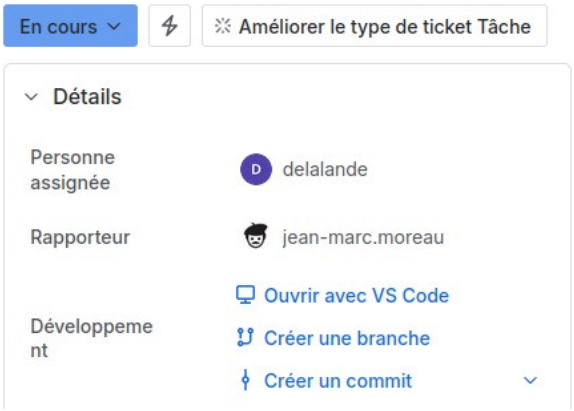

On sélectionne le projet sur lequel on travail (ici : exaetrack_scraping_webext) et on créer la branche

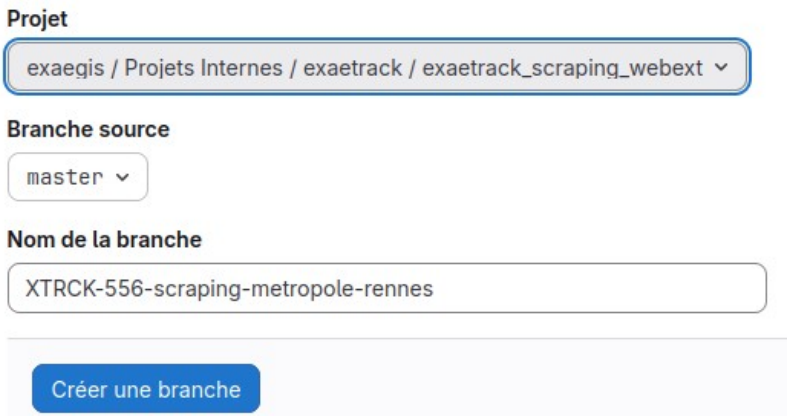

Test du script

Maintenant que l'on est positionné sur la branche, et que l'on a effectué les modification nécessaire au bon fonctionnement du script. Il faut le tester !

On lance alors le script,

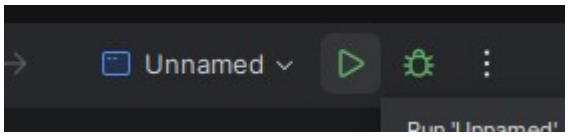

On se connecte en localhost sur le port indiqué (8080)

```
Tomcat started on port(s): 8080 (http) with context path ''
```

Et on renseigne les filtres permettant d'effectuer le scraping de la collectivité que l'on souhaite et on clique sur lancer le scraping.

A ce moment là on peut se rendre compte que le scraping est en cours

Si une erreur est renvoyé alors le script n’est pas bon.

```
: Recherche comprise entre le 01/12/2025 00:00 et le 02/01/2026 00:00
: Début de recherche : délibération

: Récupération budget ... https://mig-data.megalis.bretagne.bzh/OpenData/243500139/Deliberation/2025/983158/6a
: Content-Type: application/pdf  Content-Disposition: null  Content-Length: 140 250
: Taille doc : 140 250
: Document inséré dans S3 : dbb7b6f3-84ea-41f3-a9fb-de180f3da78a.pdf
: Document inséré dans ES : https://api.exaegis.com/documentegov/id:dbb7b6f3-84ea-41f3-a9fb-de180f3da78a
: Notation IA non configurée, le document ne sera pas noté
:  -- INFORMATIONS --
: Lien complet : https://mig-data.megalis.bretagne.bzh/OpenData/243500139/Deliberation/2025/983158/6ab2520833
: Titre : B_2025-537_Administration générale - Société anonyme d'Économie Mixte Citédia Services
: Date : 04/12/2025 00:00
: Référence : B2025_537

: Récupération budget ... https://mig-data.megalis.bretagne.bzh/OpenData/243500139/Deliberation/2025/983139/0
: Content-Type: application/pdf  Content-Disposition: null  Content-Length: 139 882
: Taille doc : 139 882
```

Une fois le scraping terminé, si tout à fonctionné correctement, un message comme celui-ci doit s’afficher

```
Documents enregistrés : 29
Erreurs : 0
Documents déjà présents : 0
XXXXX close_scraping : ok  nb : 29
Scraping terminé; OK pour RENNES
 docs ramenés : 29
scraping ok
```

Pour être sûr que ce n’est pas une erreur d’affichage et que les délibérations sont bien enregistrer, il faut se rendre sur la base de donnée et vérifier que tout les documents ont bien été enregistré. (Pour être plus concis, ici on regarde bien qu’il y a le même nombre de documents que le dis la console mais en temps normal ceci n’est évidemment pas suffisant)

29 résultat(s) sur un total de 29

La dernière étape dans le test du script, est de re-effectuer les précédentes étapes pour vérifier que le script n'ajoute pas les documents en double

```
budget déjà dans ES, on ignore : h
Documents enregistrés : 0
Erreurs : 0
Documents déjà présents : 29
XXXXX close_scraping : ok  nb : 0
Scraping terminé; OK pour RENNES
 docs ramenés : 0
scraping ok
```

Si le script fonctionne correctement (que les documents sont bien indiqués comme déjà présents). Alors il faut maintenant envoyer le travail sur la branche master. Pour cela nous devons d'abord "commit" le travail. Il est recommandé de décrire ce qui a été fait afin de faciliter la compréhension du script pour la personne qui le vérifiera et celle qui travaillera dessus

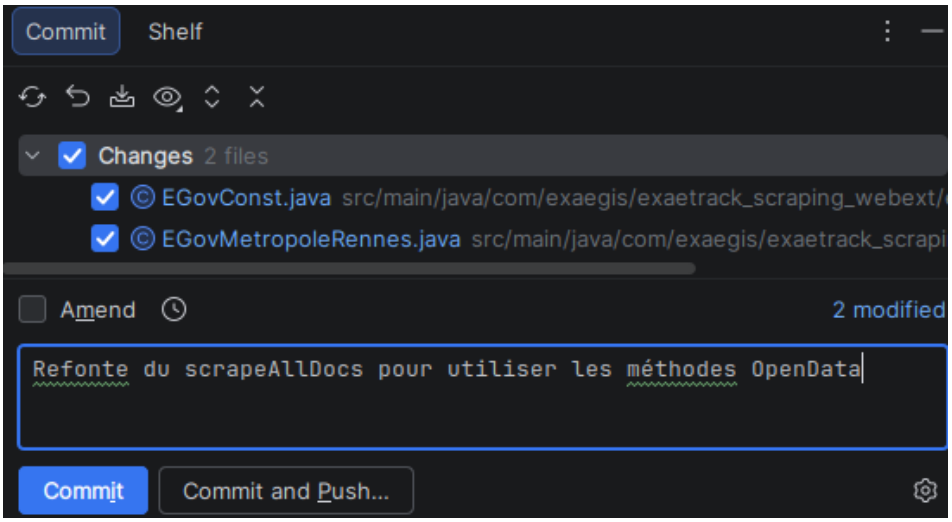
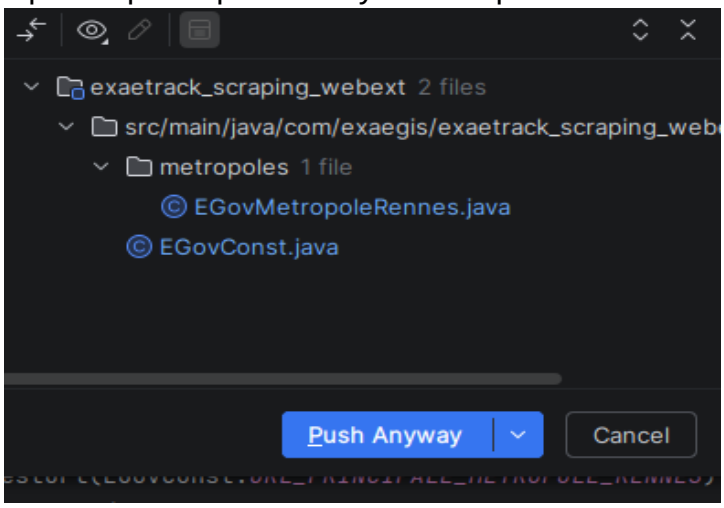
Il est désormais temps de "push" pour envoyer le script sur la branche master